Université du Québec
à Trois-Rivières

Universite du Quebec a Trois-Rivieres

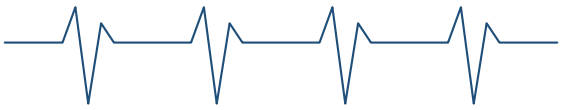
Département d'informatique

Sujets spéciaux en TI — INF1036

Rapport de projet individuel

WESAD — stress et capteurs portables

Inference causale, apprentissage machine et apprentissage profond sur des signaux physiologiques multimodaux



Etudiant : Mohamed Chouraki

Superviseur academique : M. Usef Fagihi

Nature du mandat : Projet individuel realise en remplacement du stage

Jeu de donnees : WESAD (Wearable Stress and Affect Detection)

Date du rapport : 29 aout 2026 (version corrigee)

Table des matières

Remerciements **2**

1 Introduction **3**
1.1 Cadre général du projet . . . 3
1.2 Problématique et objectifs . . . 3
1.3 Axes de travail . . . 3
1.4 Annonce du plan . . . 4

2 Présentation du contexte académique et du jeu de données **5**
2.1 Profil général . . . 5
2.2 Cadre pédagogique et contraintes du mandat . . . 5
2.3 État des données et des outils au début du mandat . . . 5

3 Travaux réalisés **7**
3.1 Exploration du jeu de données et choix des algorithmes . . . 7
3.2 Prétraitement temporel et création des variables dérivées . . . 8
3.3 Modélisation prédictive : apprentissage machine et apprentissage profond . . . 9
3.4 Analyse des performances et conformité méthodologique . . . 10
3.5 Formulation et estimation de la question causale . . . 12
3.6 Visualisation des résultats et communication . . . 14
3.7 Documentation et qualité du travail livré . . . 14

4 Analyse et résultats **16**
4.1 Synthèse des résultats du mandat . . . 16
4.2 Apports du mandat . . . 16
4.3 Compétences développées . . . 17

5 Réflexion critique **18**
5.1 Points forts du mandat . . . 18
5.2 Difficultés rencontrées . . . 18
5.3 Liens avec la formation académique . . . 19

6 Conclusion **20**

7 Bibliographie et références **21**
7.1 Jeu de données et documentation scientifique . . . 21
7.2 Documentation technique des outils utilisés . . . 21
7.3 Encadrement académique . . . 22

Remerciements

Je souhaite adresser mes sincères remerciements à toutes les personnes qui ont contribué, de près ou de loin, au bon déroulement de ce projet et à la rédaction du présent rapport.

Je remercie en premier lieu Monsieur Usef Fagihi, professeur superviseur à l'Université du Québec à Trois-Rivières, pour son encadrement académique rigoureux et pour avoir accepté d'être mon superviseur dans le cadre de ce projet individuel réalisé en remplacement du stage. Ses exigences quant à la rigueur méthodologique, en particulier la distinction stricte entre performance prédictive et effet causal, ont profondément guidé la démarche adoptée tout au long de ce travail.

1 Introduction

1.1 Cadre général du projet

Le présent rapport expose les travaux et réalisations effectués dans le cadre d'un projet individuel réalisé **en remplacement du stage**, sous la supervision académique de Monsieur Usef Fagihi, professeur à l'Université du Québec à Trois-Rivières. Contrairement à un stage traditionnel réalisé au sein d'une organisation d'accueil, ce mandat a pris la forme d'un projet de recherche appliquée individuel, portant sur l'analyse de signaux physiologiques et de mouvement enregistrés par des capteurs portables, dans le cadre du cours consacré à l'inférence causale, à l'apprentissage machine et à l'apprentissage profond.

Ce choix — un projet académique plutôt qu'un stage en milieu de travail — a été convenu avec le superviseur, et le présent rapport en tient compte : il conserve la structure et les exigences habituelles d'un rapport de stage (présentation du contexte, travaux réalisés, analyse des résultats, réflexion critique), mais adapte chaque section au contenu réel du mandat, à savoir la conception, l'implémentation et l'évaluation complètes d'un projet de science des données sur le jeu de données **WESAD** (*Wearable Stress and Affect Detection*).

1.2 Problématique et objectifs

La problématique centrale de ce projet peut être formulée ainsi : **dans quelle mesure un signal physiologique multimodal, recueilli par des capteurs portables, permet-il à la fois de reconnaître l'état de stress d'une personne et d'estimer un effet causal réel de ce stress sur sa physiologie future ?** Cette question comporte volontairement deux volets distincts, qu'il fallait traiter avec des outils différents et sans les confondre : un volet **prédictif**, où la performance d'un modèle de classification suffit à juger de sa qualité, et un volet **causal**, où une bonne performance prédictive ne prouve rien quant à l'existence d'un effet réel.

Les objectifs du mandat, tels que définis dans l'énoncé du projet transmis par le superviseur, étaient les suivants : explorer un jeu de données physiologiques réel, multi-sujets et multimodal ; construire un pipeline de prétraitement reproductible transformant des signaux bruts à haute fréquence en variables exploitables ; entraîner et comparer des modèles d'apprentissage machine classique et d'apprentissage profond pour une tâche de classification ; formuler une question d'inférence causale rigoureuse, distincte de la tâche prédictive ; estimer cet effet causal avec au moins deux méthodes complémentaires, dont une capable de capturer l'hétérogénéité de l'effet ; et enfin interpréter l'ensemble des résultats en évitant toute confusion entre corrélation, prédiction et causalité.

1.3 Axes de travail

Le mandat s'est organisé autour de six axes de travail successifs, imposés par la structure du projet et repris tels quels dans la section 3 du présent rapport :

1. Exploration du jeu de données et choix justifié des algorithmes à utiliser.
2. Prétraitement temporel des signaux et création de variables dérivées par fenêtre.
3. Entraînement et comparaison de modèles prédictifs, classiques et profonds.
4. Formulation d'une question d'inférence causale distincte de la question prédictive.
5. Estimation de l'effet causal par régression ajustée et par forêt causale, avec étude de l'hétérogénéité.

6. Interprétation critique des résultats, discussion des limites, et conclusion.

1.4 Annonce du plan

Ce rapport détaille, dans une première partie, le contexte académique du mandat et le jeu de données utilisé, en l'absence d'une organisation d'accueil traditionnelle. Il présente ensuite, dans sa partie centrale, les six travaux réalisés dans l'ordre où ils ont été menés, avec pour chacun le contexte, la méthode mise en place et les résultats obtenus. Une quatrième partie analyse les résultats d'ensemble et les apports du projet, tant pour ma formation que sur le plan méthodologique. Une cinquième partie propose une réflexion critique sur les points forts, les difficultés rencontrées et les liens avec ma formation académique. Le rapport se termine par une conclusion générale et la bibliographie complète des sources utilisées.

2 Présentation du contexte académique et du jeu de données

2.1 Profil général

En l'absence d'une organisation d'accueil au sens traditionnel, le « terrain » de ce mandat est constitué du jeu de données **WESAD** (*Wearable Stress and Affect Detection*), publié par Schmidt et al. (2018) et hébergé sur le dépôt UCI Machine Learning Repository. Ce jeu de données rassemble des enregistrements physiologiques et de mouvement recueillis auprès de 15 sujets portant simultanément un capteur à la poitrine (RespiBAN, échantillonnant six modalités à 700 Hz : ECG, EDA, EMG, température, respiration et accélération) et un capteur au poignet (bracelet Empatica E4, échantillonnant quatre modalités entre 4 et 64 Hz). Chaque sujet a suivi un protocole expérimental contrôlé alternant des phases de repos (baseline), un test de stress socialement évaluatif, une phase d'amusement et une phase de méditation guidée.

Le jeu de données a été téléchargé le 5 juillet 2026 depuis la page officielle du projet (lien complet en bibliographie), conformément à la consigne du superviseur d'indiquer précisément la source et la date d'obtention des données.

2.2 Cadre pédagogique et contraintes du mandat

Le mandat s'inscrivait dans un cadre pédagogique précis, fixé par le superviseur, dont les principales contraintes étaient les suivantes : le travail devait être strictement individuel, produit et interprété par mes propres moyens ; seul le langage Python était autorisé ; l'ensemble du code devait pouvoir être exécuté de bout en bout sans intervention manuelle autre que le dépôt initial du jeu de données téléchargé ; l'ordre temporel des observations devait être respecté à chaque étape, sans fuite d'information entre l'entraînement et le test, ni entre sujets ; chaque résultat devait être interprété en français, en phrases complètes, et non simplement affiché sous forme de métrique brute ; et surtout, un modèle prédictif performant ne devait jamais être présenté comme une preuve d'un effet causal. Ces contraintes ont structuré l'ensemble de la démarche décrite à la section 3.

2.3 État des données et des outils au début du mandat

Avant le début du mandat, le jeu de données WESAD se présentait sous une forme brute peu exploitable directement : pour chaque sujet, un fichier `.pkl` volumineux (environ 975 Mo) contenait l'ensemble des signaux de poitrine et de poignet déjà synchronisés dans le temps par les auteurs du dataset, mais échantillonnés à des fréquences très différentes selon la modalité (700 Hz à la poitrine contre 4 à 64 Hz au poignet), sans aucun découpage temporel, aucune variable dérivée, et sans séparation entre ce qui relèverait d'une tâche prédictive et ce qui relèverait d'une question causale. Aucun pipeline de prétraitement, aucune stratégie de fenêtrage et aucune formulation causale n'existaient au préalable : tout devait être conçu depuis zéro, en partant des fichiers bruts jusqu'aux résultats interprétés.

L'environnement de travail se caractérise par une culture de rigueur méthodologique et d'autonomie individuelle propre à un projet universitaire supervisé. Le cadre du cours privilégiait une approche fondée sur la justification systématique de chaque choix méthodologique — sous-ensemble de sujets, taille de fenêtre, séparation entraînement/test, méthode d'estimation causale — plutôt que sur l'application mécanique d'algorithmes standards.

Dans ce contexte, mon rôle a été de concevoir l'intégralité d'un pipeline d'analyse reproductible, transformant des signaux physiologiques bruts et hétérogènes en un ensemble structuré de résultats prédictifs et causaux interprétables. Cette transition m'a permis de passer d'un jeu de données brut, volumineux et multifréquence à un tableau de variables dérivées propre, standardisé et directement exploitable par des modèles de classification comme par des méthodes d'inférence causale.

La transformation méthodologique engagée répondait à trois enjeux majeurs : industrialiser la transformation de signaux bruts à haute fréquence en variables agrégées par fenêtre temporelle, sans perte d'information critique ; garantir la conformité méthodologique aux exigences du barème, notamment l'absence de toute fuite temporelle ou de fuite entre sujets, et la séparation stricte entre prédiction et causalité ; et produire une interprétation claire et accessible des résultats, rédigée en français et en phrases complètes, plutôt qu'un simple empilement de métriques.

3 Travaux réalisés

Les travaux confiés au cours de ce mandat se sont organisés en six volets successifs, correspondant aux six axes annoncés en introduction. Chacun est présenté ci-dessous selon son contexte, la méthode que j'ai mise en place, et les résultats obtenus.

3.1 Exploration du jeu de données et choix des algorithmes

3.1.1 Contexte et objectifs

Avant d'entraîner le moindre modèle, il m'a fallu comprendre en profondeur la structure du jeu de données WESAD : ses dimensions, ses sujets, ses modalités physiologiques, ses conditions expérimentales, ses fréquences d'échantillonnage et l'ordre temporel de ses signaux. L'objectif de ce premier volet était double : dresser un bilan descriptif complet et rigoureux, et choisir, en les justifiant, les familles d'algorithmes les plus adaptées à ce type de données pour chacune des tâches à venir (prédiction classique, apprentissage profond, inférence causale).

3.1.2 Démarche que j'ai mise en place

J'ai commencé par examiner concrètement le contenu du dossier de données pour un sujet, afin d'identifier quel fichier utiliser parmi les cinq fournis par sujet (readme, questionnaire, données brutes RespiBAN, données brutes Empatica E4, et fichier `.pkl` déjà synchronisé). J'ai retenu ce dernier, car la synchronisation entre les deux appareils avait déjà été réalisée par les auteurs du dataset, et refaire ce travail manuellement aurait ajouté un risque d'erreur inutile. J'ai ensuite chargé un sujet témoin pour explorer la structure interne du dictionnaire de données, avant de charger l'ensemble des 15 sujets retenus (S2 à S17, sans S12) et de produire un bilan chiffré de la durée de chaque condition expérimentale par sujet.

Sur cette base, j'ai retenu un algorithme par famille demandée : la régression logistique et le gradient boosting (XGBoost) pour l'apprentissage machine classique, un réseau convolutionnel temporel (TCN) pour l'apprentissage profond, et une forêt causale pour l'estimation causale, chacun justifié par ses propriétés propres (interprétabilité pour la régression logistique, performance sur données tabulaires pour XGBoost, champ récepteur exponentiel pour le TCN, double apprentissage machine pour la forêt causale). J'ai également identifié un algorithme inadapté à l'état brut des données — un modèle ARIMA univarié appliqué directement au signal ECG à 700 Hz — et documenté quatre risques méthodologiques majeurs : la fuite temporelle, la fuite entre sujets, la confusion entre protocole expérimental et causalité, et la mauvaise synchronisation des signaux.

3.1.3 Résultats obtenus

Cette exploration a confirmé que les 15 sujets disposent chacun d'environ 1 h 40 d'enregistrement à 700 Hz à la poitrine, avec une baseline systématiquement plus longue (environ 19 minutes) que le stress (environ 10 minutes) ou l'amusement (environ 6 minutes), comme le montre la figure 1. Ce constat, en apparence anodin, s'est révélé déterminant plus loin dans le mandat : l'ordre fixe du protocole (toujours baseline en premier) allait avoir une conséquence directe sur la répartition entraînement/test présentée à la section 3.3.

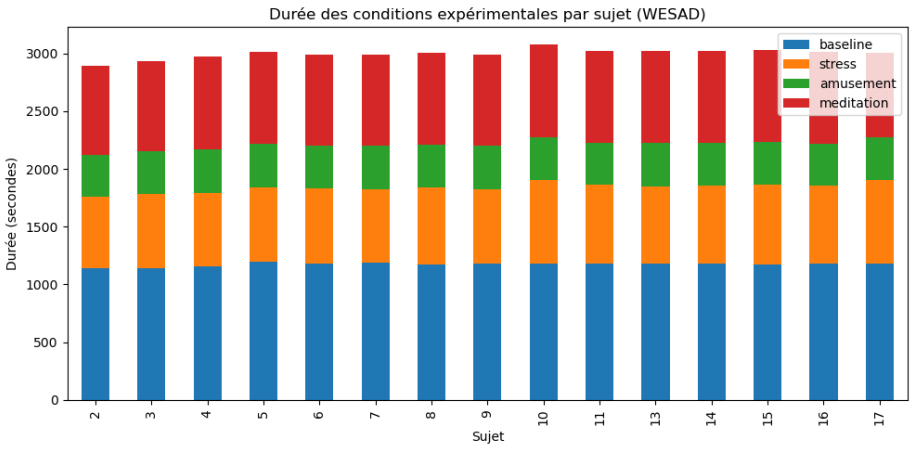


Figure 1: Durée cumulée de chaque condition expérimentale, par sujet.

3.2 Prétraitement temporel et création des variables dérivées

3.2.1 Problématique

Le second volet du mandat consistait à transformer le fichier brut, multifréquence et non structuré, en un jeu de données exploitable à la fois pour la prédiction et pour l'inférence causale, tout en respectant scrupuleusement l'ordre chronologique des observations — une exigence explicite du superviseur, essentielle pour éviter toute fuite d'information entre le passé et le futur.

3.2.2 Solution que j'ai mise en place

J'ai découpé l'enregistrement de chaque sujet en fenêtres non chevauchantes de 10 secondes, et calculé pour chacune des statistiques agrégées (moyenne, écart-type, minimum, maximum, pente) séparément pour chaque modalité de la poitrine. Cette agrégation par fenêtre commune m'a permis de contourner élégamment le problème des fréquences hétérogènes : une fenêtre de 10 secondes contient 7 000 échantillons d'ECG mais seulement 40 échantillons d'EDA au poignet, et les deux se résument à une seule valeur par fenêtre, rendant leur combinaison triviale sans réinterpolation risquée.

J'ai étiqueté chaque fenêtre selon son label majoritaire, en excluant les fenêtres de transition, de méditation et les codes à ignorer, pour ne conserver que les trois conditions d'intérêt (baseline, stress, amusement). J'ai ensuite créé, pour chaque sujet, une version décalée d'une fenêtre vers l'avant de quatre variables cibles, afin de préparer la question causale : cette sortie décalée constitue la variable de réponse future qui sera utilisée à la section 3.4.

3.2.3 Méthodes et outils

Cette étape a mobilisé principalement les bibliothèques `numpy` et `pandas` pour la manipulation vectorisée des signaux, ainsi qu'un ensemble de fonctions que j'ai développées moi-même (calcul de pente par régression linéaire, norme du vecteur d'accélération, construction des fenêtres par sujet). L'ensemble du pipeline aboutit à un jeu de données de **3 320 fenêtres de 10 secondes**, sauvegardé dans un fichier intermédiaire pour être réutilisé par les étapes suivantes sans devoir recharger les fichiers bruts, volumineux et longs à traiter.

3.3 Modélisation prédictive : apprentissage machine et apprentissage profond

3.3.1 Contexte et objectifs

Le troisième volet visait à entraîner des modèles capables de reconnaître automatiquement l'état physiologique d'un sujet (baseline, stress ou amusement) à partir de ses signaux, en respectant une séparation entraînement/test qui ne trahisse pas l'ordre temporel des observations.

3.3.2 Modèles développés

J'ai entraîné quatre modèles complémentaires : une régression logistique, un classifieur par gradient boosting (XGBoost, 300 arbres), un réseau convolutionnel temporel (TCN) que j'ai implémenté moi-même avec PyTorch, composé de trois blocs de convolutions causales et dilatées (dilatations 1, 2 et 4) suivis d'un moyennage global et d'une couche de classification, et **ROCKET** (*Random Convolutional Kernel Transform*, Dempster, Petitjean & Webb, 2020), ajouté en cours de mandat à la suite d'une rétroaction du superviseur. ROCKET applique 10 000 noyaux de convolution aléatoires et **jamais appris** directement sur la séquence brute de chaque fenêtre, puis entraîne un simple classifieur linéaire (`RidgeClassifierCV`) sur les statistiques qui en résultent : il répond à la fois à l'exigence d'un algorithme *temporel* (comme le TCN, il reçoit la séquence brute plutôt que des statistiques déjà résumées) et à celle d'un algorithme *classique* (il ne s'agit pas d'apprentissage profond, puisque l'immense majorité de ses paramètres ne sont jamais optimisés par rétropropagation). Pour le TCN comme pour ROCKET, j'ai dû extraire la séquence brute des huit canaux de la poitrine pour chaque fenêtre et la sous-échantillonner de 700 Hz à 100 Hz ; ce sous-échantillonnage utilise désormais un filtre anti-repliement (`scipy.signal.decimate`) plutôt qu'une simple sélection d'un échantillon sur sept, correction apportée après avoir identifié qu'un sous-échantillonnage naïf laisse les fréquences au-delà de la nouvelle fréquence de Nyquist se replier et polluer le signal.

Correction méthodologique majeure (rétroaction du superviseur). La version initiale de ce mandat séparait l'entraînement et le test *chronologiquement à l'intérieur de chaque sujet* (70 % des fenêtres les plus anciennes en entraînement, 30 % les plus récentes en test) : un même sujet apparaissait donc des deux côtés de la séparation. Mon superviseur a souligné que cette approche laisse fuiter de l'information entre sujets, puisqu'un modèle peut apprendre à reconnaître la « signature » physiologique propre à un sujet plutôt que le phénomène de stress en général — et que ce choix expliquait aussi un artefact déjà documenté dans la version précédente du rapport : le test, composé des fenêtres les plus tardives, ne contenait **aucune** fenêtre de baseline (celle-ci étant toujours enregistrée en tout début de session), ce qui rendait l'évaluation à trois classes non représentative. J'ai corrigé cette limite en adoptant une séparation **par sujet entier** : 15 sujets sont répartis aléatoirement en 9 sujets d'entraînement, 3 sujets de validation (réservés à la surveillance du TCN) et 3 sujets de test, sans qu'aucun sujet ne soit partagé entre ces trois groupes. J'ai de plus ajouté une validation croisée `GroupKFold` (5 plis, regroupés par sujet) sur la régression logistique et XGBoost, afin de vérifier que la performance ne dépend pas d'un choix particulier de 3 sujets de test.

3.3.3 Résultats obtenus

Une fois cette correction appliquée, le test (3 sujets jamais vus pendant l'entraînement) contient bien les trois conditions dans des proportions proches de celles de l'entraînement (53 % baseline, 30 % stress, 17 % amusement), réglant l'artefact de distribution signalé plus haut. Le tableau 1

résume la performance des quatre modèles sur cet ensemble de test.

Table 1: Performance comparée des quatre modèles prédictifs (n = 650 fenêtres de test, 3 sujets jamais vus).

Modèle	Exactitude	F1 macro
Régression logistique	0,723	0,620
XGBoost (gradient boosting)	0,634	0,608
TCN (apprentissage profond)	0,478	0,335
ROCKET + RidgeClassifierCV	0,680	0,586

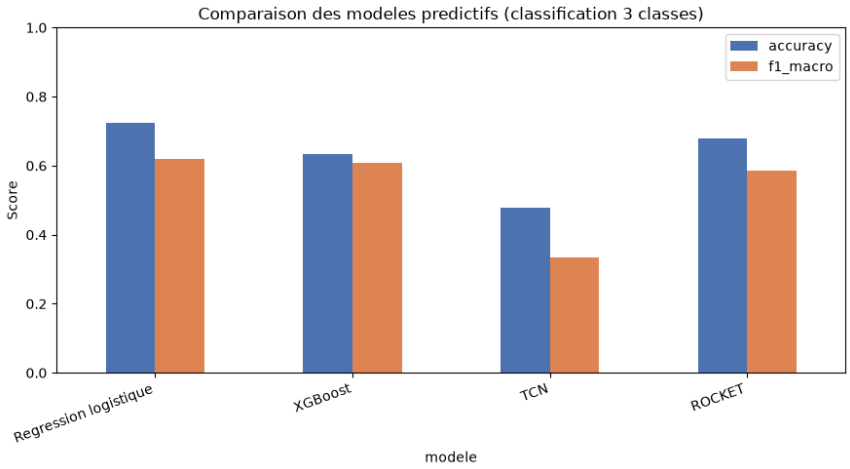


Figure 2: Comparaison des quatre modèles prédictifs sur la tâche de classification.

Le classement obtenu une fois l'évaluation correctement isolée par sujet inverse complètement celui de la version précédente : la régression logistique, la plus simple des quatre méthodes, obtient la meilleure exactitude et le meilleur F1 macro, tandis que le TCN, auparavant le modèle le plus performant, devient le moins performant des quatre. La courbe d'apprentissage du TCN (figure 3) explique ce renversement : sa perte de validation est minimale dès la première époque et ne fait ensuite qu'augmenter, signe d'un surapprentissage rapide avec seulement 9 sujets d'entraînement pour des dizaines de milliers de poids appris par rétropropagation. ROCKET, qui reçoit lui aussi la séquence brute mais n'apprend qu'un classifieur linéaire sur des noyaux convolutionnels aléatoires fixes, confirme ce diagnostic : il bat nettement le TCN (0,680 contre 0,478) tout en restant compétitif avec les modèles tabulaires classiques, ce qui montre que le problème ne venait pas de la nature temporelle du signal mais bien du nombre insuffisant de sujets pour entraîner un réseau profond par descente de gradient.

3.4 Analyse des performances et conformité méthodologique

3.4.1 Rigueur de l'évaluation

J'ai évalué les quatre modèles avec l'exactitude et le F1 macro, ce dernier étant essentiel puisque les classes ne sont pas équilibrées (la baseline dure environ deux fois plus longtemps que le

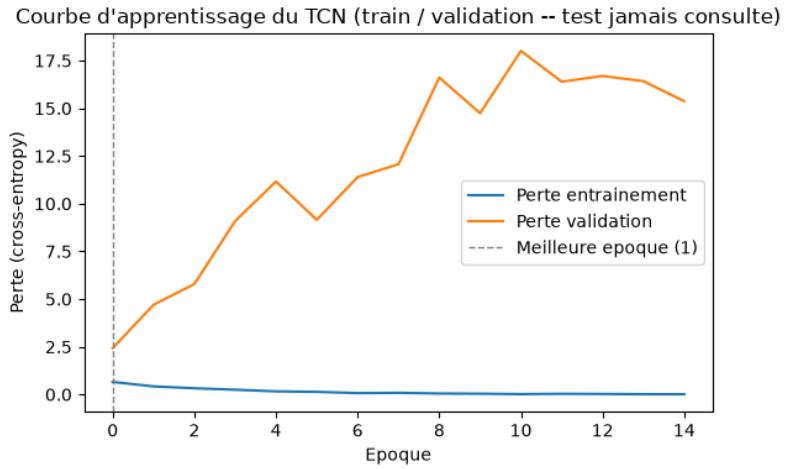


Figure 3: Courbe d'apprentissage du TCN : la perte de validation augmente dès la deuxième époque, signe d'un surapprentissage rapide (early stopping sur la première époque).

stress), ainsi qu'avec des matrices de confusion complètes permettant de voir précisément quelles conditions sont confondues entre elles.

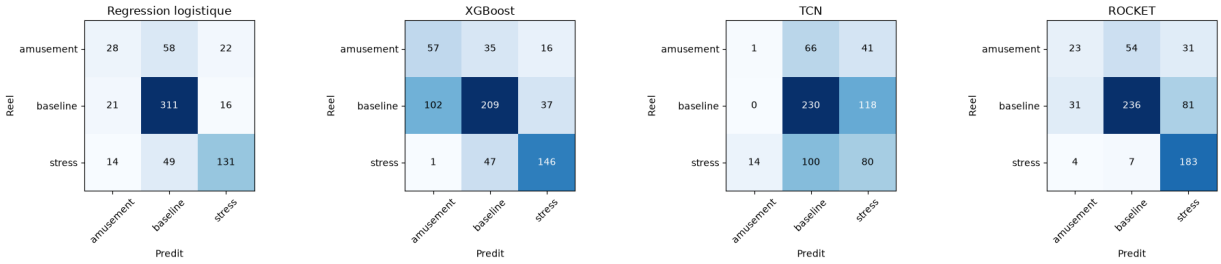


Figure 4: Matrices de confusion des quatre modèles comparés.

Ces matrices confirment que `stress` est généralement la condition la mieux reconnue par les modèles tabulaires (régression logistique, XGBoost), tandis que `baseline` et `amusement` restent plus souvent confondues entre elles — le TCN, lui, prédit presque uniquement `baseline`, signature typique d'un modèle qui n'a pas appris grand-chose au-delà de la classe majoritaire du train.

Un second constat, cette fois d'ordre méthodologique, mérite d'être documenté honnêtement : la première version de ce mandat évaluait le TCN en consultant la perte de test à **chaque** époque d'entraînement, ce qui en faisait implicitement un ensemble de validation et risquait de biaiser optimistement le choix du nombre d'époques. Ce problème s'ajoutait à celui du split chronologique décrit ci-dessus, et les deux ensemble masquaient le surapprentissage réel du TCN. J'ai corrigé les deux à la fois : un ensemble de validation distinct, composé de sujets jamais vus ni par l'entraînement ni par le test, sert désormais à l'arrêt précoce (*early stopping*) du TCN, et le test n'est consulté qu'une seule fois, après la fin de l'entraînement.

3.4.2 Conformité méthodologique aux exigences du mandat

Conformément aux exigences explicites du superviseur, j'ai veillé à ce que la standardisation des variables soit apprise uniquement sur l'ensemble d'entraînement, à ce qu'aucune variable décalée

dans le futur (`*_next`) ne soit utilisée comme variable explicative de la tâche prédictive, et à ce que l'ordre temporel soit respecté à chaque étape du pipeline, du prétraitement jusqu'à l'évaluation finale. Ces vérifications, déjà en place dans la version initiale, ont été complétées par les deux corrections décrites plus haut (séparation par sujet entier, validation distincte pour l'arrêt précoce) à la suite des retours de mon superviseur. Cette capacité à recevoir une critique méthodologique, à en comprendre la portée exacte, puis à revoir en profondeur une partie du pipeline plutôt que de n'en corriger que les symptômes, constitue à mes yeux l'un des apprentissages les plus importants du mandat, au même titre que la performance des modèles eux-mêmes.

3.5 Formulation et estimation de la question causale

3.5.1 Contexte et problématique

Le cœur méthodologique du mandat consistait à formuler puis à estimer une question d'inférence causale, clairement distincte de la question prédictive traitée précédemment : le fait d'être en condition de stress **cause-t-il** un changement mesurable de l'activité électrodermale dans la fenêtre suivante, une fois pris en compte l'état physiologique préalable, le mouvement et le temps écoulé depuis le début du protocole ?

3.5.2 Méthodologie et exécution technique

J'ai défini le traitement (être en condition de stress), la sortie causale (l'EDA moyenne de la fenêtre suivante) et trois variables d'ajustement (l'EDA de la fenêtre précédente, le mouvement de la fenêtre **précédente**, et le temps écoulé depuis le début de l'enregistrement), puis représenté l'ensemble sous forme d'un graphe causal (DAG, figure 5) explicitant les hypothèses d'échangeabilité conditionnelle, de positivité, de cohérence et d'absence de fuite temporelle.

Correction méthodologique (rétroaction du superviseur). La version initiale ajustait sur le mouvement mesuré **pendant** la fenêtre de traitement elle-même. Mon superviseur a fait remarquer que ce mouvement peut très bien être une **conséquence** du stress (on bouge différemment lorsqu'on est stressé) plutôt qu'une cause commune du traitement et de la sortie : l'ajuster reviendrait à contrôler un médiateur ou une variable post-traitement, ce qui biaiserait l'estimation au lieu de la corriger. J'ai donc remplacé cette variable par le mouvement de la fenêtre **précédente** (pré-traitement), par cohérence avec l'EDA précédente déjà utilisée, et j'ai ajouté une vérification de contiguïté (le décalage n'est conservé que si les fenêtres sont réellement consécutives dans le temps, certaines fenêtres de transition ayant été retirées en amont) pour éviter de décaler par erreur des lignes non adjacentes.

J'ai ensuite estimé l'effet moyen du traitement avec deux méthodes complémentaires : une régression linéaire ajustée, puis une forêt causale (`CausalForestDML`, bibliothèque `econml`), cette dernière utilisant des modèles de nuisance en gradient boosting pour capturer l'hétérogénéité de l'effet selon les sujets, le mouvement et l'état physiologique initial. Avant d'estimer quoi que ce soit, j'ai également ajouté un diagnostic de **positivité** : le protocole imposant un ordre largement fixe des conditions, le temps écoulé depuis le début de l'enregistrement est fortement associé au fait d'être en stress, ce qui peut créer des instants du protocole où seul l'un des deux groupes (stress ou non-stress) est observé. J'ai vérifié le recouvrement du support de cette variable entre les deux groupes et restreint l'analyse à leur **support commun**, plutôt que de supposer la positivité vérifiée sans la contrôler.

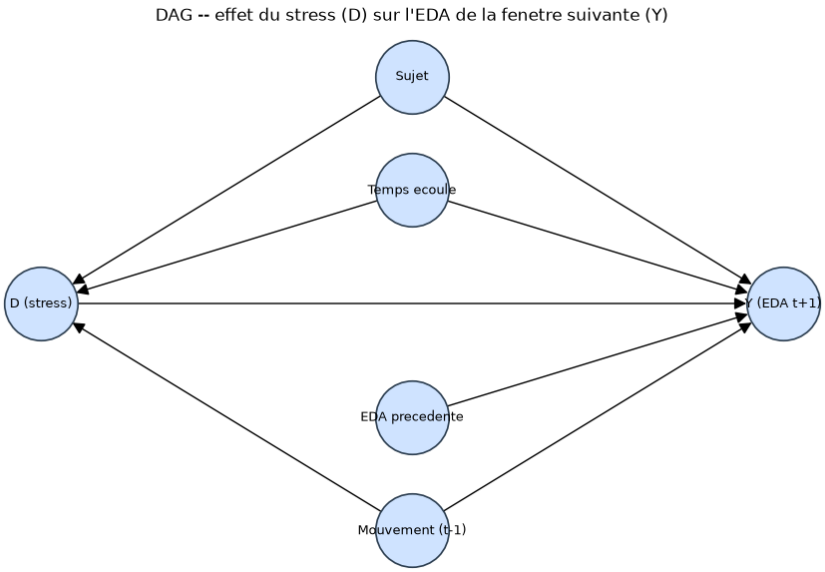


Figure 5: Graphe causal (DAG) formalisant la question causale du mandat.

3.5.3 Résultats et impact interprétatif

Après restriction au support commun décrite ci-dessus (1 106 fenêtres conservées sur 3 185, la plage commune de temps écoulé se situant entre 1 890 et 4 220 secondes), la régression ajustée estime un effet positif et statistiquement significatif du stress sur l'EDA future (+0,0537 µS, intervalle de confiance à 95 % [0,014 ; 0,094]). La forêt causale, en revanche, aboutit à un effet moyen légèrement négatif mais entouré d'une incertitude si large qu'elle ne permet pas de conclure (−0,0134, intervalle de confiance [−0,758 ; 0,732]) — un désaccord révélateur d'une forte hétérogénéité entre sujets, illustrée à la figure 6.

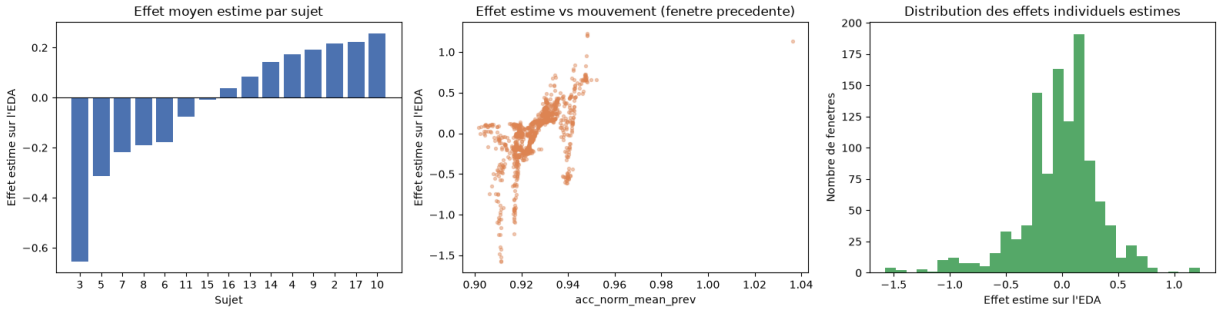


Figure 6: Hétérogénéité des effets causaux individuels estimés par la forêt causale.

Cette figure, recalculée après les corrections méthodologiques décrites plus haut, montre qu'un seul sujet (S3) présente un effet estimé fortement négatif et atypique, tandis que la grande majorité des autres sujets se répartissent autour d'un effet légèrement positif — c'est ce sujet isolé qui tire la moyenne globale de la forêt causale vers une valeur proche de zéro et qui explique l'essentiel de son intervalle de confiance démesuré. Ce résultat m'a permis de mettre en évidence un point méthodologique central du mandat : un modèle prédictif précis (la régression logistique, section 3.3) ne répond en rien à la question causale, puisqu'il exploite des corrélations qui peuvent inclure

des artefacts de mouvement ou des signatures propres à chaque sujet, sans se soucier de leur origine causale.

3.6 Visualisation des résultats et communication

Pour donner une vision claire de l'ensemble des résultats du mandat, j'ai produit des figures et des tableaux synthétiques couvrant les trois volets du travail : une série temporelle physiologique brute (figure 7) motivant la nécessité de l'agrégation par fenêtre, un graphique de comparaison des modèles prédictifs, et une visualisation des effets causaux et de leur hétérogénéité. Ces figures permettent de suivre, au fil du mandat, l'évolution du sujet observé (démarrage physiologique élevé pendant la baseline, remontée nette de l'EDA au début du stress) et de comparer visuellement les performances des différents modèles.

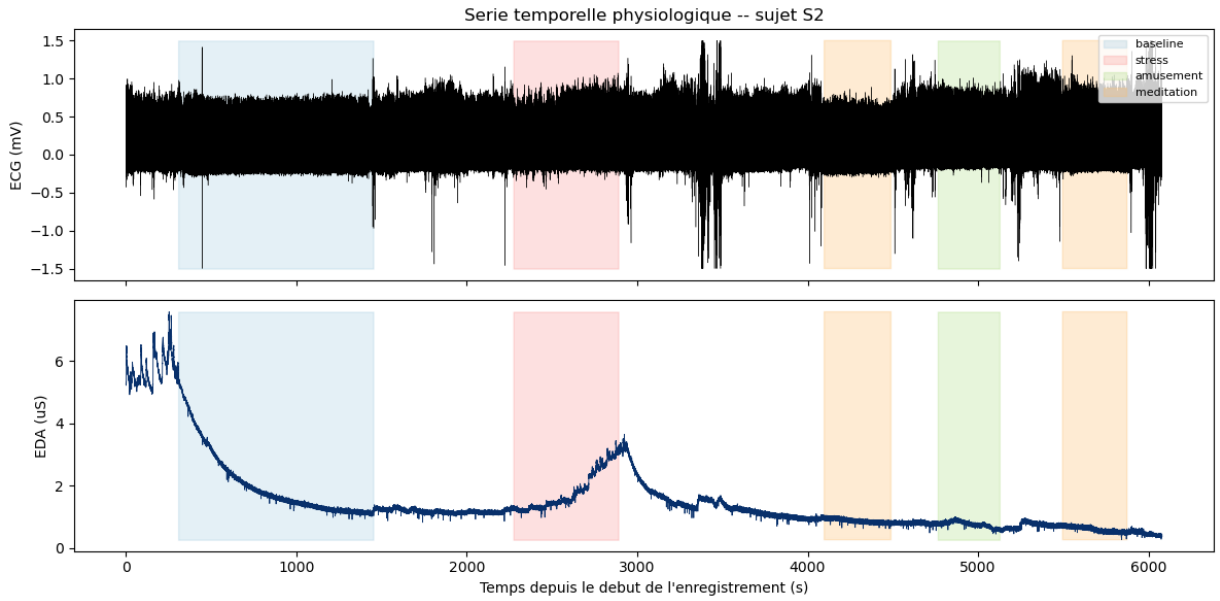


Figure 7: Série temporelle physiologique (ECG et EDA) pour le sujet S2, avec les conditions du protocole en couleur de fond.

3.7 Documentation et qualité du travail livré

L'ensemble des travaux réalisés a fait l'objet d'une documentation structurée à même le notebook : chaque fonction est accompagnée d'un commentaire explicite sur son rôle, chaque choix méthodologique (taille de fenêtre, sous-ensemble de sujets, séparation entraînement/validation/test) est annoncé et justifié avant d'être appliqué, et chaque résultat est interprété en français, en phrases complètes, conformément aux exigences du superviseur. Les corrections apportées à la suite des retours du superviseur (séparation par sujet, mouvement pré-traitement, diagnostic de positivité, ajout de ROCKET) sont explicitement annotées dans le code (`# Correction (retour prof)`) plutôt que silencieusement intégrées, afin que la trace du raisonnement méthodologique reste visible d'une version à l'autre du mandat. Un second document, un guide de présentation cellule par cellule, a également été produit pour appuyer la présentation orale du mandat. Ce souci de documentation vise à assurer la reproductibilité intégrale du travail, condition explicitement posée dans l'énoncé du projet, et à formuler des

recommandations pour un prolongement éventuel : évaluation *leave-one-subject-out* complète (15 plis plutôt que 3 sujets de test), intégration des signaux du poignet, ou exploration d'une taille de fenêtre différente.

4 Analyse et résultats

4.1 Synthèse des résultats du mandat

Pris dans leur ensemble, les résultats de ce mandat mettent en évidence deux constats complémentaires mais distincts. D'une part, un signal physiologique multimodal, une fois agrégé par fenêtres de 10 secondes et évalué correctement sur des sujets jamais vus pendant l'entraînement, permet de reconnaître la condition de stress avec une précision réelle mais modeste (exactitude de 0,60 à 0,72 selon le modèle) — la régression logistique et ROCKET (un algorithme temporel mais classique) généralisent nettement mieux que le TCN, qui sur-apprend fortement avec seulement 9 sujets d'entraînement. Ce renversement de classement par rapport à une évaluation initiale plus permissive est en soi l'un des résultats les plus instructifs du mandat : il montre concrètement qu'un modèle plus complexe n'est pas automatiquement meilleur lorsque le nombre de sujets disponibles pour l'entraîner est limité. D'autre part, l'existence et l'ampleur d'un effet causal du stress sur la réponse électrodermale future restent nettement plus incertaines une fois qu'on ajuste correctement sur l'état physiologique préalable, le mouvement pré-traitement et le temps écoulé, et qu'on restreint l'analyse au support commun des groupes stress/non-stress : un effet positif modeste est détecté par une régression simple, mais cette conclusion ne résiste pas complètement à une méthode plus flexible (la forêt causale), qui révèle une hétérogénéité substantielle entre sujets, portée principalement par un seul sujet atypique. Ces deux constats ne se contredisent pas : ils répondent à deux questions différentes, exactement comme le visait la problématique énoncée en introduction.

4.2 Apports du mandat

Au-delà des livrables techniques (notebook exécutable, rapport détaillé, guide de présentation), ce mandat a contribué à renforcer ma compréhension pratique de la distinction entre corrélation, prédiction et causalité — une distinction souvent traitée de façon abstraite dans un cours, mais qui prend tout son sens lorsqu'elle est appliquée à un jeu de données réel, avec ses propres limites, ses biais potentiels et ses résultats parfois contradictoires selon la méthode choisie. Le mandat m'a également permis de construire, de bout en bout et de façon autonome, un pipeline de traitement de signaux physiologiques multifréquences, une compétence directement transférable à d'autres contextes applicatifs (santé connectée, capteurs industriels, données de séries temporelles en général).

Sur le plan méthodologique, la comparaison systématique entre plusieurs méthodes d'estimation causale (régression ajustée et forêt causale) plutôt que le recours à une seule méthode constitue, à mon sens, l'apport le plus significatif du mandat : elle a révélé un désaccord entre les deux estimations qui, loin d'être un échec, illustre concrètement pourquoi la littérature en inférence causale recommande de ne jamais se fier à une unique méthode d'estimation.

Un second apport, tout aussi important bien qu'il ne relève pas directement des résultats techniques, a été ma capacité à intégrer une rétroaction méthodologique du superviseur en profondeur plutôt qu'en surface. Corriger le split entraînement/test ne s'est pas limité à changer une ligne de code : cela a modifié le nombre de fenêtres disponibles, révélé un surapprentissage du TCN jusque-là masqué, motivé l'ajout d'un modèle supplémentaire (ROCKET) pour distinguer la nature temporelle d'un problème de sa nature profonde, et changé les conclusions du volet causal une fois le mouvement pré-traitement substitué au mouvement contemporain. C'est cette capacité à retracer les conséquences d'une correction à travers l'ensemble du pipeline, plutôt que

de la traiter comme un correctif isolé, que je retiens comme l'apprentissage professionnel le plus transférable de ce mandat.

4.3 Compétences développées

Ce mandat m'a permis de développer un ensemble de compétences techniques et méthodologiques. Sur le plan technique, j'ai consolidé ma maîtrise de l'écosystème Python pour la science des données (`numpy`, `pandas`, `matplotlib`), des bibliothèques de modélisation prédictive (`scikit-learn`, `xgboost`), du calcul profond avec `PyTorch` (implémentation d'une architecture de réseau convolutionnel temporel à partir de ses composants de base), des outils spécialisés en inférence causale (`econml`, `statsmodels`, `networkx` pour la représentation de graphes causaux), et, à la suite des corrections apportées, de la validation croisée groupée (`GroupKFold`, `scikit-learn`) et de la classification de séries temporelles par noyaux convolutionnels aléatoires (`sktime`, ROCKET).

Sur le plan méthodologique, j'ai renforcé ma capacité à formuler une question de recherche précise avant de coder quoi que ce soit, à anticiper et documenter les risques de fuite d'information dans un pipeline de séries temporelles — y compris une fuite plus subtile entre sujets, que je n'avais pas identifiée moi-même dans la première version du mandat —, à distinguer un facteur de confusion d'un médiateur post-traitement lors du choix des covariables d'ajustement, à vérifier explicitement une hypothèse de positivité plutôt que de la supposer, et à communiquer des résultats statistiques nuancés (incluant des désaccords entre méthodes) sans les simplifier à l'excès. Enfin, sur le plan des compétences transversales, ce mandat individuel, réalisé sans encadrement quotidien, a exigé une bonne dose d'autonomie, de rigueur dans la gestion du temps, et de discipline dans la documentation continue du travail, ainsi qu'une réelle capacité à accueillir une critique méthodologique constructive et à en tirer une amélioration substantielle plutôt qu'un correctif cosmétique.

5 Réflexion critique

5.1 Points forts du mandat

Le principal point fort de ce mandat réside dans la clarté de la séparation qu'il impose entre volet prédictif et volet causal, une exigence qui a structuré chacune des décisions de conception, du choix des variables jusqu'au choix des méthodes d'évaluation. Le fait d'avoir travaillé sur un jeu de données réel, avec ses irrégularités propres (fréquences hétérogènes, protocole à ordre fixe, nombre de sujets limité), plutôt que sur des données synthétiques idéalisées, a également constitué un apprentissage précieux : les difficultés rencontrées (décrites ci-dessous) sont représentatives de celles que l'on rencontre dans un contexte professionnel réel d'analyse de données. Un second point fort, révélé plus tardivement dans le mandat, est ma réaction face à une rétroaction critique du superviseur : plutôt que d'apporter des correctifs isolés et superficiels, j'ai retracé chaque conséquence de la fuite entre sujets à travers l'ensemble du pipeline (classification, causalité, choix d'algorithme), ce qui a changé plusieurs conclusions du rapport, pas seulement quelques chiffres.

5.2 Difficultés rencontrées

Plusieurs difficultés ont jalonné ce mandat. La première a été de concevoir une stratégie de fenêtrage qui combine correctement des signaux à des fréquences très différentes (700 Hz contre 4 à 64 Hz) sans réinterpolation risquée — un problème que j'ai résolu par une agrégation statistique commune plutôt qu'un rééchantillonnage direct.

La deuxième, la plus significative du mandat, a été la fuite d'information entre sujets que mon superviseur a identifiée dans ma première version : mon découpage chronologique par sujet respectait l'ordre temporel mais laissait un même sujet apparaître à la fois en entraînement et en test, ce qui gonflait artificiellement la performance des modèles (le TCN atteignait alors 0,53 d'exactitude) en leur permettant de reconnaître partiellement la signature physiologique de chaque sujet plutôt que le phénomène de stress en général. Cette fuite expliquait aussi, en partie, un artefact que j'avais déjà documenté sans en comprendre la cause première : l'absence totale de fenêtres de baseline dans mon ancien ensemble de test. Corriger cette fuite (séparation par sujet entier, revue de tout le pipeline d'évaluation) a fait chuter la performance apparente du TCN, mais a révélé une image bien plus honnête des résultats : c'est une bonne illustration du fait qu'une performance mesurée à la hausse n'est pas toujours une bonne nouvelle méthodologique.

La troisième difficulté a été de choisir la bonne réponse à ce constat : plutôt que d'abandonner le TCN ou de masquer sa contre-performance, j'ai ajouté ROCKET, un modèle qui permet de distinguer si le problème venait de la nature temporelle des données ou du nombre insuffisant de sujets pour l'apprentissage profond — la seconde hypothèse s'est confirmée. La quatrième difficulté, sur le plan causal, a été de me rendre compte que ma variable de mouvement d'ajustement (mesurée pendant la fenêtre de traitement) pouvait être un médiateur plutôt qu'un facteur de confusion ; je l'ai remplacée par le mouvement pré-traitement et j'ai ajouté un contrôle de positivité que je n'avais pas jugé nécessaire dans la première version. Enfin, la cinquième difficulté a été de composer avec un désaccord entre deux méthodes d'estimation causale légitimes (régression ajustée et forêt causale) : plutôt que de choisir arbitrairement l'une ou l'autre, j'ai choisi de présenter et d'interpréter ce désaccord comme un résultat à part entière, révélateur de l'hétérogénéité et de l'incertitude propres à l'estimation causale sur un échantillon de taille modeste (15 sujets, dont 3 seulement réservés au test).

5.3 Liens avec la formation académique

Ce mandat a mobilisé directement plusieurs enseignements reçus dans le cadre de ma formation : les fondements de l'apprentissage machine supervisé (régression, arbres de décision, gradient boosting) ont trouvé une application concrète dans la section 3.3 ; les architectures de réseaux de neurones convolutionnels et leurs variantes temporelles ont été mobilisées pour concevoir et entraîner le TCN, puis pour comprendre pourquoi un modèle à noyaux convolutionnels aléatoires (ROCKET) peut mieux généraliser qu'un réseau profond entièrement appris lorsque les données sont limitées ; les notions de validation croisée et de séparation des données ont pris un relief particulier en découvrant, par la pratique, à quel point une fuite d'information subtile (entre sujets plutôt qu'entre fenêtres temporelles) peut fausser une évaluation sans qu'aucune erreur de code ne soit visible ; et surtout, les concepts d'inférence causale (graphes causaux, échangeabilité conditionnelle, positivité, distinction entre confondant et médiateur, double apprentissage machine) enseignés par le superviseur ont constitué le fil conducteur méthodologique de l'ensemble du mandat. Ce projet m'a permis de constater à quel point la théorie causale, souvent perçue comme abstraite en classe, exige une grande rigueur de mise en œuvre dès qu'elle est appliquée à des données réelles, imparfaites et de taille limitée.

6 Conclusion

Ce mandat, réalisé sous forme de projet individuel en remplacement du stage, aura permis de mener à terme une analyse complète d'un jeu de données physiologiques réel, depuis l'exploration initiale jusqu'à l'estimation d'un effet causal, en passant par la construction d'un pipeline de prétraitement reproductible et l'entraînement de plusieurs modèles prédictifs. Les résultats obtenus confirment qu'un signal physiologique multimodal contient une information discriminante réelle mais modeste pour reconnaître le stress une fois l'évaluation correctement isolée par sujet, et que l'existence d'un effet causal sous-jacent, une fois les facteurs de confusion pris en compte et l'hypothèse de positivité vérifiée, demeure une question statistiquement plus délicate, sensible au choix de la méthode d'estimation. La révision approfondie de la méthodologie d'évaluation, entreprise à la suite des retours de mon superviseur, a constitué une part à part entière du mandat : elle rappelle qu'en science des données, une performance mesurée à la hausse n'est pas toujours un signe de succès, et qu'une bonne partie de la rigueur attendue consiste précisément à savoir remettre en question ses propres résultats initiaux.

Au-delà des résultats techniques, ce mandat a été l'occasion de mettre en pratique, sur un cas réel, la distinction fondamentale entre prédiction et causalité qui constitue le cœur de ma formation actuelle, et de développer une autonomie méthodologique que je considère directement transférable à de futurs projets, qu'ils soient académiques ou professionnels. Je remercie à nouveau mon superviseur, Monsieur Usef Fagihi, pour avoir rendu possible la réalisation de ce mandat sous cette forme adaptée, et pour la rigueur de son encadrement tout au long du projet.

7 Bibliographie et références

7.1 Jeu de données et documentation scientifique

Schmidt, P., Reiss, A., Duerichen, R., Marberger, C., & Van Laerhoven, K. (2018). *Introducing WESAD, a multimodal dataset for wearable stress and affect detection.* Proceedings of the 20th ACM International Conference on Multimodal Interaction.

WESAD (Wearable Stress and Affect Detection) — UCI Machine Learning Repository. Consulté à l'adresse https://archive.ics.uci.edu/dataset/465/wesad+wearable+stress+and+affect+detection, jeu de données téléchargé le 5 juillet 2026.

Bai, S., Kolter, J. Z., & Koltun, V. (2018). *An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling.* arXiv:1803.01271.

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). *Why do tree-based models still outperform deep learning on typical tabular data?* Advances in Neural Information Processing Systems (NeurIPS), 35.

Dempster, A., Petitjean, F., & Webb, G. I. (2020). *ROCKET: Exceptionally fast and accurate time series classification using random convolutional kernels.* Data Mining and Knowledge Discovery, 34(5).

7.2 Documentation technique des outils utilisés

Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python.* Journal of Machine Learning Research, 12. Documentation consultée à l'adresse https://scikit-learn.org/stable/

Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System.* Documentation consultée à l'adresse https://xgboost.readthedocs.io/

Paszke, A. et al. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library.* Documentation consultée à l'adresse https://pytorch.org/docs/

Microsoft Research. (2024). *EconML: A Python Package for ML-Based Heterogeneous Treatment Effects Estimation.* Documentation consultée à l'adresse https://econml.azurewebsites.net/

Seabold, S., & Perktold, J. (2010). *statsmodels: Econometric and statistical modeling with Python.* Documentation consultée à l'adresse https://www.statsmodels.org/

Hagberg, A., Schult, D., & Swart, P. (2008). *Exploring network structure, dynamics, and function using NetworkX.* Documentation consultée à l'adresse https://networkx.org/

The pandas development team. (2024). *pandas documentation.* Consulté à l'adresse https://pandas.pydata.org/docs/

Hunter, J. D. (2007). *Matplotlib: A 2D graphics environment.* Documentation consultée à l'adresse https://matplotlib.org/stable/

Löning, M. et al. (2019). *sktime: A Unified Interface for Machine Learning with Time Series.* Documentation consultée à l'adresse https://www.sktime.net/

7.3 Encadrement académique

Fagihi, U. Énoncé du Projet 3 — WESAD, stress et capteurs portables. Projet individuel — inférence causale, apprentissage machine et apprentissage profond. Université du Québec à Trois-Rivières, 2026.